



UNIVERSIDAD INDUSTRIAL DE SANTANDER

Reporte Técnico: Etapa 1

Construcción de la Base de Conocimiento

CODEFEST AD ASTRA 2026

Henry Dario Mantilla Claro

Nelson Fabian Perez Perez

Jeferson Jair Acevedo Sarmiento

Brayan Yesid Quintero Santander

Agosto 2026

1. Arquitectura General y Metodología de Validación

El sistema sigue el flujo natural de un pipeline de recuperación: primero se extrae el texto de cada documento, luego se limpia y se fragmenta, después se codifica semánticamente, se indexa en FAISS y finalmente se recupera de forma híbrida ante cada consulta. A esto se suma un componente opcional, el grafo de conocimiento, que no funciona como una pieza aparte sino que se integra directamente al proceso de recuperación como una fuente más de evidencia.

La recuperación combina cuatro señales: dos espacios de *embeddings* densos, un canal léxico basado en BM25 y el grafo de conocimiento. Estas cuatro señales se funden mediante *Reciprocal Rank Fusion* y el resultado se refina con un modelo de reordenamiento.

Antes de entrar en el detalle de cada componente, vale la pena explicar cómo se probaron y ajustaron los parámetros del sistema, porque ese proceso es tan importante como los valores finales que se reportan. No se contaba con el conjunto completo de 50 consultas oficiales para validar decisiones de diseño mientras se construía el sistema, así que la validación se apoyó en una muestra parcial de referencia, `FASE ORDENADA CODEFEST.xlsx`, que contiene 7 consultas con sus documentos y fragmentos relevantes ya identificados. Cada configuración candidata se evaluó contra esa muestra usando las mismas dos métricas oficiales del reto, $F1@3$ para documentos y $NDCG@10$ para fragmentos.

Es importante ser honestos sobre el alcance de esa validación: con solo 7 consultas, ambas métricas se mueven en saltos grandes y discretos, lo que hace que muchos cambios de parámetro parezcan no tener efecto simplemente porque la muestra es demasiado pequeña para detectarlo, o que un cambio real se vea como ruido. Por esa razón, las decisiones que se describen a continuación distinguen explícitamente entre las que están respaldadas por una mejora medida en ambas métricas oficiales a la vez, y las que se adoptaron por razonamiento directo sobre el comportamiento del corpus, sin que la muestra pequeña alcance todavía para confirmarlas con la misma solidez.

2. Modelos Utilizados

Emplear dos encoders densos, y no solo el de mejor desempeño individual, responde a algo que se midió directamente sobre el corpus: cerca del 74 % de los documentos están redactados en inglés, mientras que la totalidad de las 50 consultas de evaluación están en español. Contar con un encoder capaz de comparar contenido entre idiomas no es una opción entre varias equivalentes, sino la decisión que determina si el sistema puede encontrar contenido relevante en inglés a partir de una pregunta hecha en español.

Cada vector se normaliza a norma unitaria antes de indexarse,

$$\hat{v} = \frac{v}{\|v\|_2}, \quad v = \phi(t) \in \mathbb{R}^{1024},$$

de modo que el producto interno entre dos vectores normalizados sea numéricamente igual a la similitud coseno entre ellos: $\cos(\hat{q}, \hat{v}) = \hat{q} \cdot \hat{v}$.

3. Estrategia de *Chunking*

Se combinaron dos de las estrategias que la especificación del reto describe como válidas: la fragmentación jerárquica, que respeta los encabezados y divisiones del documento como frontera obligatoria entre fragmentos, y la fragmentación semántica con superposición, que la propia especificación recomienda para reducir el riesgo de que una idea relevante quede partida entre dos

Modelo	Rol	Licencia	Justificación
multilingual-e5-large	Encoder denso 1	MIT	Multilingüe, 1024 dimensiones.
BAAI/bge-m3	Encoder denso 2	MIT	Segundo espacio semántico, entrenado con un objetivo distinto al de e5; al fusionar ambos rankings se recupera contenido relevante que uno solo de los dos deja en posiciones bajas.
BM25 (propio, sin modelo)	Canal léxico	—	Coincidencia exacta de términos: siglas, topónimos, nombres de grupos armados que un encoder denso puede pasar por alto.
urchade/gliner_multi-v2.1	NER <i>zero-shot</i> (grafo)	Apache-2.0	Modelo de tipo <i>encoder</i> que permite definir en tiempo de inferencia los tipos de entidad relevantes para el dominio del corpus.
BAAI/bge-reranker-v2-m3	Reordenamiento	MIT	<i>Cross-encoder</i> que discrimina con precisión dentro de un conjunto ya preseleccionado de candidatos, corrigiendo los casos donde la recuperación densa deja el fragmento correcto en una posición baja. Su uso fue confirmado como admisible por los organizadores en las preguntas frecuentes del reto, al aclarar que la restricción sobre modelos generativos aplica a arquitecturas de tipo <i>decoder</i> y no a los <i>cross-encoders</i> .

Cuadro 1: Modelos empleados en indexación y recuperación. Ninguno de ellos es generativo: los dos encoders y GLiNER son arquitecturas *encoder* puras, y el *reranker* es una cabeza de regresión escalar montada sobre un *encoder*.

fragmentos consecutivos. En la práctica, esto significa que un encabezado de sección nunca se cruza al fragmentar, y que dentro de cada sección las oraciones se acumulan hasta alcanzar un tamaño objetivo, con cada fragmento nuevo retomando una parte del final del fragmento anterior en lugar de empezar desde cero.

El tamaño objetivo y la superposición no se eligieron por convención propia, sino que se calcularon a partir del comportamiento real de los organizadores. El archivo `FASE ORDENADA CODEFEST.xlsx` incluye fragmentos de referencia ya extraídos de sus documentos de origen. Localizando en qué posición exacta, a nivel de carácter, aparece cada uno de esos fragmentos dentro de su PDF original, y dividiendo esa posición entre el número de orden del fragmento, se puede reconstruir el paso real que los organizadores usaron entre fragmentos consecutivos:

$$\text{paso} \approx \frac{\text{posición}(\text{fragmento}_i)}{i} \approx 708 \text{ caracteres.}$$

Esta medición se repitió sobre nueve fragmentos de seis documentos distintos y dio un resultado consistente: una mediana de 156 palabras por fragmento, equivalente a 1067 caracteres, con una superposición implícita de 350 caracteres. El paso de 708 caracteres es menor que el tamaño del fragmento precisamente porque cada fragmento nuevo comparte esos 350 caracteres finales con el

anterior.

A partir de esa evidencia se adoptaron los parámetros finales del sistema: un tamaño objetivo de aproximadamente 1000 caracteres y una superposición de aproximadamente 350 caracteres. Esta decisión se tomó de forma deliberada frente a la alternativa más obvia, que habría sido diseñar el tamaño del fragmento en función del límite de salida de 250 palabras. Ese límite es una cota máxima sobre lo que se entrega al final, no una indicación de qué tamaño usaron los organizadores al construir su propio material de referencia, que resultó ser considerablemente más pequeño. Replicar el tamaño real que ellos usaron, y no solo respetar el límite superior, es lo que permite que la fragmentación del sistema quede alineada con la granularidad contra la que efectivamente se evalúa.

El corte respeta siempre oraciones completas: se retrocede hasta el final de la última oración completa que cabe dentro del presupuesto de caracteres, usando un segmentador de texto con reglas de protección para abreviaturas y decimales, de modo que expresiones como `EE.UU.` o `3.5 millones` no se interpreten por error como el final de una oración. Cada fragmento incorpora además el título del documento de origen, pero únicamente en el texto que se codifica semánticamente, nunca en el texto que se conserva como resultado final. La razón es que un resumen corto, sin un encabezado propio que lo distinga, se convierte fácilmente en un fragmento genérico que la búsqueda densa termina emparejando con consultas que no tienen relación real con su contenido; anteponerle el título del documento le da al modelo de embeddings la señal de origen que el encabezado de sección, por sí solo, no puede ofrecer.

4. Gestión del Índice FAISS

El almacenamiento y la búsqueda de los vectores generados se realiza con `IndexFlatIP` de FAISS, un índice de búsqueda exacta por producto interno, y no uno aproximado. Esta decisión se apoya en tres razones.

La primera es de escala: con aproximadamente 135 000 a 140 000 fragmentos por encoder, comparar un vector de consulta contra la totalidad del índice cuesta del orden de $n \cdot d \approx 1,4 \times 10^8$ operaciones, algo que se resuelve en milisegundos sobre hardware convencional. Estructuras como `IndexIVFFlat` o `IndexHNSW` existen para escenarios donde ese costo deja de ser trivial, lo cual no ocurre a esta escala.

La segunda es que la propia especificación del reto recomienda explícitamente esta elección para el volumen de documentos esperado, señalando que un índice plano resulta suficiente y garantiza resultados exactos, y reservando los índices aproximados para corpus de mayor escala o para escenarios donde el tiempo de respuesta sea crítico.

La tercera razón es menos evidente pero igual de importante: `IndexFlatIP` asigna sus identificadores internos de forma secuencial, en el mismo orden en que se insertan los vectores. Esa propiedad es la que permite que el identificador de cada fragmento en el archivo de metadata coincida, línea por línea, con el identificador interno del índice, sin necesidad de una capa adicional de mapeo. Un índice aproximado normalmente exigiría una estructura extra para garantizar esa misma correspondencia.

5. Módulo de Recuperación

Ante una consulta, el sistema construye un ranking por cada uno de los cuatro canales de evidencia y los combina mediante *Reciprocal Rank Fusion*, un método robusto frente al hecho de

que las puntuaciones de los distintos canales no son directamente comparables entre sí:

$$s_{RRF}(c) = \sum_{j=1}^m \frac{w_j}{k_0 + r_j(c)}, \quad k_0 = 60,$$

donde $r_j(c)$ es la posición del fragmento c dentro del ranking del canal j .

Cómo participa el grafo en la recuperación

Ante cada consulta, se identifican qué entidades del vocabulario del grafo están nombradas en el texto de la consulta. A partir de esas entidades se recuperan dos tipos de evidencia: los fragmentos que mencionan directamente a la entidad, y los fragmentos que mencionan a sus vecinos de primer orden dentro del grafo, con un descuento aplicado a estos últimos. El resultado es un ranking más, con su propia lista ordenada de fragmentos, que se funde con los otros tres mediante la misma fórmula de *Reciprocal Rank Fusion* descrita arriba, el grafo no recibe ningún trato especial en la fusión, entra a competir en igualdad de condiciones con los canales densos y el léxico.

Ponderación de los canales

La ponderación de cada canal fue, de todas las decisiones documentadas en este informe, la que más se revisó a partir de evidencia. En una configuración inicial, los cuatro canales tenían el mismo peso, y eso generó un sesgo medible hacia el español. La razón es que BM25 solo puede votar por un fragmento cuando sus términos coinciden literalmente con los de la consulta, y como las 50 consultas están escritas en español, BM25 termina favoreciendo sistemáticamente contenido en español, mientras que los canales densos sí son capaces de emparejar una consulta en español con contenido semánticamente equivalente en inglés. Bajo pesos iguales, un fragmento en español recibía el voto de los cuatro canales a la vez, mientras que uno en inglés, aunque fuera más relevante para la pregunta, solo podía recibir el voto de los dos canales densos. Se confirmó este efecto de forma directa sobre los fragmentos recuperados: el 79 % estaban en español, frente a un corpus compuesto en un 74 % por documentos en inglés.

Como corrección, se redujo a la mitad el peso tanto de BM25 como del grafo, quedando en $w_{BM25} = 0,5$ y $w_{grafo} = 0,5$, ambos se ajustaron juntos porque comparten la misma limitación de fondo: ninguno de los dos puede establecer correspondencias entre idiomas distintos. Estos son los valores que el sistema usa por defecto. Vale la pena mencionar, con la misma honestidad con la que se describió la metodología de validación al inicio de este informe, que una comparación preliminar sobre la muestra de 7 consultas sugirió que devolverle al grafo su peso original ($w_{grafo} = 1,0$) podría mejorar el resultado una vez corregido el sesgo de BM25, dado que el grafo no comparte la limitación monolingüe de BM25. Esa comparación no alcanzó a completarse con una muestra lo bastante grande como para adoptarla con la misma confianza que el resto de las decisiones de este informe, así que el sistema conserva el valor de 0.5 y esa alternativa queda documentada como línea de trabajo futura, no como una mejora ya confirmada.

Reordenamiento

Sobre los primeros $d_{rerank} = 150$ candidatos del ranking fusionado, un modelo de tipo *cross-encoder* vuelve a puntuar cada par consulta-fragmento, y su orden se combina con el orden fusionado previo en lugar de reemplazarlo por completo:

$$s_{blend}(c) = (1 - \beta) \frac{1}{k_{rr} + r_{RRF}(c)} + \beta \frac{1}{k_{rr} + r_{cross}(c)}, \quad \beta = 0,5, \quad k_{rr} = 10.$$

Combinar ambos órdenes, en lugar de sustituir uno por el otro, evita que el *cross-encoder* descarte un fragmento en el que los demás canales ya coincidían de forma unánime, a cambio de una

señal más fina dentro del grupo de candidatos. Al igual que con el peso del grafo, una comparación preliminar sugirió que ampliar la profundidad de reordenamiento a 400 candidatos podría mejorar el resultado, pero por la misma razón de tamaño de muestra esa alternativa tampoco se adoptó todavía como valor por defecto.

Agregación de documentos

La forma en que se agregan los fragmentos a nivel de documento no fue la primera que se intentó, y vale la pena explicar por qué cambió. El diseño inicial ordenaba los documentos por la similitud coseno de un único encoder, elegido de forma arbitraria, el primero en orden alfabético entre las carpetas del índice, y le asignaba a cada documento la puntuación de su mejor fragmento individual. Ese diseño tenía un problema real: un documento con un único fragmento muy bueno superaba a otro con varios fragmentos moderadamente relevantes, porque solo se consideraba el máximo, nunca la evidencia acumulada. En la práctica esto llevó a que, para algunas consultas, hasta la mitad de los candidatos de más alto puntaje quedaran concentrados en un solo documento, dejando muy poca diversidad real entre los tres documentos finalmente devueltos.

El diseño actual corrige esto de dos maneras a la vez. Primero, agrega los documentos a partir del mismo ranking ya fusionado y reordenado que produce los fragmentos finales, no de un cálculo aparte basado en un solo encoder. Segundo, en lugar de quedarse con el mejor fragmento de cada documento, suma la contribución de todos sus fragmentos presentes en ese ranking, con un peso que decae a medida que se consideran fragmentos adicionales del mismo documento:

$$\text{score}(d) = \sum_{i=0}^{n_d-1} \frac{1}{k_0 + r_i + 1} \cdot \gamma^i, \quad \gamma = 0,85.$$

De esta forma, un documento con varios fragmentos moderadamente relevantes puede superar a uno con un único fragmento sobresaliente, que es precisamente lo que la métrica de evaluación de documentos busca premiar: no qué fragmento aislado responde mejor, sino qué documentos, en conjunto, responden la consulta.

Filtro de fenómeno

Un fragmento cuyo fenómeno temático coincide con el rango de identificadores de la consulta recibe una bonificación en su puntuación, no una exclusión de los que no coinciden —la correspondencia entre el identificador de la consulta y su fenómeno se infiere, no está publicada por los organizadores, así que un posible error de inferencia debe costarle al fragmento algunas posiciones en el ranking, nunca sacarlo por completo de la lista de candidatos:

$$s'(c) = s(c) + \beta(\text{máx}(S) - \text{mín}(S)) \cdot \mathbb{I}[\text{fenomeno}(c) = \text{fenomeno}(q)], \quad \beta = 0,20.$$

La bonificación se expresa como una fracción del rango de puntuaciones del propio conjunto de candidatos, en lugar de un número fijo, precisamente para que ese mismo valor de β tenga el mismo efecto relativo sin importar en qué espacio de puntuación se esté aplicando. Con la versión anterior, que usaba una constante fija, se midió una fuga de fenómeno del 18 % sobre los candidatos agrupados; con esta versión escalada, la fuga bajó a 11.2 % en fragmentos y 7.3 % en documentos sobre la entrega final.

Deduplicación

Un fragmento candidato se descarta si su solapamiento de *shingles* de ocho palabras contra uno ya seleccionado supera un umbral de $\tau = 0,45$. Ese umbral se calibró directamente sobre la geometría real de este corpus: ventanas adyacentes de texto presentan un solapamiento cercano a 0.31, mientras que contenido republicado de forma casi idéntica, el mismo artículo publicado, por

ejemplo, tanto en PDF como en JSON por el mismo observatorio alcanza cerca de 0.95. El umbral de 0.45 se sitúa con margen por encima del primer caso, para no descartar fragmentos vecinos que aportan contexto genuinamente distinto, y con margen por debajo del segundo, para sí capturar los duplicados reales.

Trazabilidad

Cada fragmento y cada documento que el sistema devuelve conserva la trazabilidad completa hasta el texto original: el `chunk_id` y el `doc_id` de cada fragmento en `resultados.jsonl` corresponden exactamente a un registro en `metadata.jsonl`, que a su vez guarda el texto sin modificar y la posición del fragmento dentro de su documento de origen. Antes de escribir el archivo final, el propio script de generación valida que cada consulta tenga exactamente tres documentos y diez fragmentos, y que cada fragmento cumpla con los campos obligatorios que exige la especificación, de modo que un problema de formato se detecte antes de la entrega y no durante la evaluación.

6. Grafo de Conocimiento

Extracción y mapeo de entidades (NER): Empleamos GLiNER (*encoder zero-shot*, alineado con la restricción no generativa del reto) para detectar categorías de dominio específico, mapeándolas a cuatro etiquetas base del grafo: **ORG** (organizaciones y militares), **GPE** (entidades geopolíticas), **LOC** (ubicaciones físicas) y **MISC** (tratados, tecnología y activos espaciales).

Ventana deslizante y normalización: Para superar el límite interno de 384 tokens de GLiNER y evitar truncamientos silenciosos, segmentamos los fragmentos en ventanas superpuestas por palabras. Las entidades resultantes se normalizan (minúsculas, acentos, siglas y equivalencias multilingües) para unificar variantes en un único nodo.

Filtrado de entidades: Filtramos entidades por frecuencia: eliminamos el ruido de muy baja aparición y marcamos los términos de frecuencia excesiva para revisión humana (evitando descartar términos clave del dominio como “NASA” o “China”).

Extracción de relaciones: Las aristas se identifican por patrones lingüísticos (verbos) o coocurrencia en el mismo fragmento. Las relaciones por simple coocurrencia se podan mediante un umbral mínimo de repetición, mientras que las relaciones con patrón verbal explícito se conservan siempre.

7. Resumen: Parámetros Finales

8. Cumplimiento de la Sección 8.3 del reto

Ningún componente del sistema es generativo. Los dos encoders y GLiNER son arquitecturas de tipo *encoder*, sin ninguna cabeza generativa: GLiNER selecciona sus *spans* mediante producto punto y una función sigmoide, no mediante muestreo autoregresivo. El modelo de reordenamiento es una cabeza de regresión escalar montada sobre un *encoder*, y su uso fue confirmado como admisible directamente por los organizadores. La fusión por *Reciprocal Rank Fusion*, la agregación de documentos, el filtro de fenómeno y la deduplicación son operaciones aritméticas sobre rangos y puntuaciones, sin ningún modelo de por medio. Las relaciones del grafo se extraen mediante patrones lingüísticos, un método que la especificación reconoce explícitamente como aceptable. En ninguna etapa del sistema hay reformulación de la consulta, filtrado basado en generación de texto, ni síntesis de resultados.

Parámetro	Valor	Evidencia
Encoders	e5-large + bge-m3	Decisión de diseño
Índice FAISS	IndexFlatIP	Exacto por escala y por recomendación del spec
<i>Chunk</i> / solape	≈ 1000 / ≈ 350 car.	Reconstruido del ground truth oficial
w_{BM25}	0.5	Medido: corrige el sesgo de idioma
w_{grafo}	0.5	Mismo motivo que w_{BM25} ; subirlo a 1.0 está
d_{rerank}	150	Valor por defecto; ampliarlo a 400 está
β_{blend} (rerank)	0.5	Mejor entre las alternativas probadas
γ (decaimiento doc.)	0.85	Razonado; sin señal distinguible aún en muestra pequeña
$\beta_{fenomeno}$	0.20 / 0.30	Razonado desde diagnóstico de fuga medida
τ_{dedup}	0.45	Calibrado sobre la geometría real del corpus
GLiNER <i>threshold</i> / ventana	0.35 / 150 palabras	Ventana ajustada tras observar truncamiento real
τ_{arista} (grafo)	2	Preserva relaciones con verbo identificado siempre

Cuadro 2: Parámetros finales empleados en la entrega. Los dos marcados como pendientes mostraron una mejora preliminar en la muestra de validación de 7 consultas, pero no se adoptaron como valor por defecto por no alcanzar a confirmarse con una muestra mayor antes de la entrega.